

HAUTE ÉCOLE D'INGÉNIERIE ET DE GESTION DU
CANTON DE VAUD



GESTION ET VALORISATION DE PROJET DE MACHINE LEARNING
GML

Crapauduc - 2022

Authors:

Schaller JORIS
D'Ancona OLIVIER
Logan VICTORIA
Akoumba ERICA LUDIVINE
Wichoud NICOLAS

January 5, 2023

Contents

1	Introduction	1
2	Gestion du projet	3
2.1	Organisation du projet	3
2.2	Gestion du temps de travail	3
2.3	Gestion des tâches et répartition	4
3	Outils	5
3.1	Colabeler	5
3.2	Conversion de format	5
3.3	Comptage des labels	5
3.4	Folder Shortener	5
3.5	Fusion des dataframes	5
4	Data preparation	6
4.1	Acquisition des données	6
4.2	Stockage des Données	6
5	Filtrage	8
5.1	Analyse des données labellisées	8
5.1.1	Analyse temporelle	9
5.1.2	Analyse météorologique	10
5.2	Détecteur de planches	10
6	Modèles	12
6.1	Choix des modèles	12
6.2	Les échecs	12
6.3	FASTER R-CNN	13
6.4	RETINA net	13
6.5	DEtection Transformer (DE-TR)	13
7	Evaluation	15
7.1	Section1	15
7.1.1	Features	15
8	Comptage	17
8.1	Section1	17
8.1.1	Features	17

Chapter 1

Introduction

Ce projet de machine learning nous a été proposé dans le cadre du cours de Gestion et valorisation de projet en Machine Learning (GML), donné au cours du cinquième semestre du cursus de Bachelor en Informatique et système de communication orienté ingénierie des données à la HEIG-VD. Le but de ce travail est de nous faire découvrir la gestion et organisation impliquée par un travail de machine learning, autant au niveau de la recherche technologique qu’au niveau de l’organisation d’équipe, notamment au niveau de la distribution de tâches, gestion d’équipe et de délais.

Le projet décrit ici est un projet existant ayant déjà été réalisé plusieurs fois par le professeur et de précédents étudiant.e.s : l’étude de crapauducs. Un crapauduc est un “petit conduit sous une route, permettant le passage protégé des batraciens” - selon Le Robert. En 2017, dix-huit crapauducs ont été construits le long de la route d’Aubonne à Gimel - canton de Vaud - afin de permettre aux grenouilles, crapauds et tritons de traverser la route des bois à l’étang en toute sécurité, L’image 1.1 en montre un..

À l’intérieur de ces crapauducs ont été installée une caméra équipée d’un capteur, qui implique la prise d’une petite série de photos (*Figure 1.2*) lors de la détection de mouvement, ainsi qu’une planche afin de faciliter la distinction des objets du sol. Comptant moins de caméras que de crapauducs, les caméras n’étaient pas rattachée à un crapauduc et comptent donc des images prises depuis différents crapauducs.



Figure 1.1: Un des 18 crapauducs installés pour l’étude




Figure 1.2: Exemples des images d’amphibiens prises par les cameras

Au terme de la première année d’utilisation, ces voies ont été empruntées par plus de 6’000 crapauds, grenouilles et tritons confondus. Ce comptage a été effectué par des chercheurs, qui ont du regarder les images prises par les caméras et compter les animaux ”à la main”. Le projet Crapauduc vise ainsi à utiliser l’apprentissage automatique (Machine Learning) pour automatiser le comptage des batraciens.

Notre objectif pour ce projet est donc de détecter la présence ou non de grenouille/crapaud et tritons (en considérant les grenouilles et crapauds comme une seule et même catégorie) en utilisant l’apprentissage automatique, ce afin de déterminer si la constructions de ces crapauducs est efficace. Pour se faire, nous avons les prises des caméras du 23 février 2017 au 20 avril de la même année, totalisant près de 1 million d’images, dont on connaît pour chacune la caméra dont elle provient ainsi que le moment où la photo a été prise (date, heure, minute et seconde).

Enfin, le professeur Satizabal Mejia Hector Fabio nous a également mis à disposition sa labelisation pour certaines images, des bounding box pour certaines également, ainsi que les données météo enregistrées durant cette période (notamment la température, le vent, la précipitation et l’humidité).

Chapter 2

Gestion du projet

2.1 Organisation du projet

Dès le départ, nous avons décidé de travailler avec git, plus précisément sur github. Nous avons donc créé une organisation afin de séparer les différents dépôts. Nous en avons définis 2, mais les membres de l'organisation étaient libres d'en ajouter d'autres.

- **crapauduc**. Ce dépôt est le dépôt principal où les notebooks des modèles sont déposés, nous y avons aussi placé les rapports des anciens étudiants afin d'y avoir un accès rapide. Nous y avons aussi déposé un subset d'image d'environ 0.5 GiB permettant le fine tuning.
- **utils**. Ce dépôt contient des scripts faisant des transformations ou des analyses sur les données. Nous y avons par exemple un script qui permet de convertir les annotations de csv à COCO.

De plus, nous avons créé un compte google ayant le doux nom de **student GML** afin d'avoir un espace google drive de 15 GiB pour stocker les données ainsi qu'une intégration facilitée dans le service colab de Google. Nous croyions être prêts.

2.2 Gestion du temps de travail

Dès le départ, nous avons décidé de travailler à distance afin de dédier la totalité de la journée à ce projet sans perdre de temps dans les transports publics. En effet, le mardi où tombe le cours de GML, nous n'avons pas d'autre cours que ce dernier. Ainsi, un mardi typique se déroule comme suit:

- 8h00 - 13h15: Libre, mais souvent on prépare la séance de l'après-midi.
- 13h15 - 15h: Appel Teams, où nous expliquons notre avancement, normalement les différents problèmes rencontrés doivent être réglés avant la réunion. Planification des tâches pour la prochaine semaine, et répartition des tâches. Durant chaque réunion un membre du groupe prend des notes afin d'avoir un historique des discussions, ce procès verbal des réunions est stocké sur le google drive de **student GML**.

La séance du mardi se résume donc essentiellement à un partage d'information entre les différents groupes de travail composé de 1 à 3 étudiant.e.s. Le travail proprement dit est pour la plupart effectué en dehors des réunions, soit le mardi après la réunion soit à un autre moment choisis par les membres du groupe.

2.3 Gestion des tâches et répartition

Nous avons poussé notre utilisation de github, en gérant nos tâches à l'aide de l'outil de gestion de projet kanban directement intégré dans github. Ainsi, nous pouvons savoir à n'importe quel moment quel membre de l'équipe travail sur quelle partie du projet. De plus, nous pouvons voir les tâches en cours, les tâches terminées, les tâches en attentes, etc.

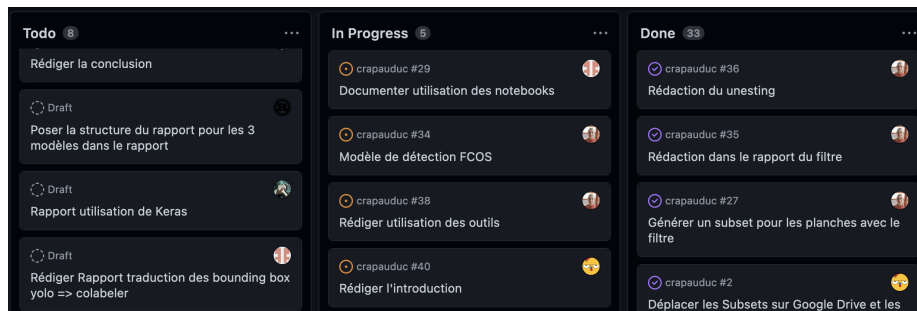


Figure 2.1: Nos tâches du Kanban réparties en 3 catégories : à faire, en cours et terminées.

critique: Nous avons décidé de ne pas élire de responsable au sein des étudiants. Cette décision a bien fonctionné pour certains aspects du travail, comme par exemple la prise des notes durant les réunions. Cependant les appels Teams étaient généralement coordonnés par Olivier et Joris sans vraiment que cela ait été prévu. Ce n'était pas voulu puisque nous souhaitions une organisation horizontale, mais cette manière de fonctionner s'est imposé naturellement et nous avons gardé cette organisation pour la suite. Par coordination nous entendons de manière générale animer la discussion et amorcer les points suivants. L'organisation de travail a elle aussi subi des changements au cours du projet. Au début, nous avons travaillé de manière très individuelle sur les petites tâches initiales. Nous souhaitions pouvoir travailler de manière très parallèle et ce choix semblait fut bon. Néanmoins, cela nous a fait par la suite rencontrer deux nouveaux problèmes:

1. Friction lors de la communication.
2. Tâches trop complexes pour une seule personne.

Notre organisation initiale fonctionnait bien au début du projet puisque nous avons beaucoup de petites tâches et nous avons bien avancé. Cependant, les tâches devenant de plus en plus grosses, les réunions ont pris de plus en plus de temps. En effet, nous avons rencontré beaucoup de problèmes qui étaient difficiles à résoudre seul, nous en discutons donc durant les réunions, et celles-ci commencent à prendre trop de temps. Après quelques séances peu efficaces, nous avons réalisé qu'il serait plus judicieux de travailler en petits groupes afin qu'une partie de la communication se fasse déjà entre les membres du sous-groupe et ainsi que l'on réduise les informations à partager lors des réunions. De plus travailler à plusieurs permettait de surmonter les problèmes rencontrés plus facilement.

Chapter 3

Outils

But Nous avons constitué un repository github contenant des scripts permettant de transformer les données brutes en données utilisables pour l'analyse. Ces scripts sont disponibles dans le repository `utils` sur github.

3.1 Colabeler

Afin de réaliser les bounding box et les labels, nous avons utilisé le logiciel Colabeler permettant d'annoter les images pour l'object detection. Ainsi nous pouvons ajouter des bounding box facilement et rapidement. Il a été utilisé dans le cadre de la création du filtre et dans la constitution du dataset de test.

3.2 Conversion de format

Nous avons écrit un petit script python permettant de convertir les labels en différents formats. Il existe plusieurs manières de définir les bounding box. Elle peuvent être définies comme un point d'ancrage et une taille plus une hauteur ou simplement être 2 points. De plus, il existe différentes nomenclatures pour stocker ces images telles que le format coco stocké dans un fichier `.json` qui est associé au dataset coco. Il se peut que les données soient encore stockées sous forme d'un `csv` ou d'un fichier `manifest` qui peut être utile pour des services comme amazon sagemaker.

3.3 Comptage des labels

Un petit script a été mis sur pied afin de compter les labels déjà effectués. Ce qui permet d'avoir une liste des images déjà traitées et de constituer un subset rapidement pour entraîner des algorithmes.

3.4 Folder Shortener

Ce script bash permet de simplifier le chemin d'accès aux images pour une question de clarté et d'entretien du projet.

3.5 Fusion des dataframes

Chapter 4

Data preparation

4.1 Acquisition des données

Problème Lors de ce projet, les données doivent être accessibles à tous les membres et doivent être stockées de manière uniformisée pour faciliter le travail de groupe. Nous avons alors opté pour une structure regroupant les images par caméra et le nom de fichier correspondant est la date ISO standardisée de la date de la prise du fichier.

Source Nous avons récupéré un disque dur comprenant les 500GB dans le bureau de nos professeurs. La structure de fichier était partitionnée par caméra, année, jour, heure, minute. Cette structure était pratique pour naviguer dans les dossiers mais posait un problème pour extraire les informations car les métadonnées étaient stockées dans le path du fichier et non dans un fichier .csv externe. La nouvelle structure partitionnée par caméra permet d’avoir toutes les images regroupées et ainsi d’avoir les métadonnées au même endroit. Nous avons ainsi écrit des scripts de transformations que l’on peut trouver dans le repository utils sur github.

Format Les images sont au format JPEG, toutes les images sont de la même taille, 1920x1080 pixels.

Numéro de séquence Une information qui n’était pas présente originellement était le numéro de séquence des images. Lorsque la caméra détectait un mouvement continu, la même action pouvait résulter sur plusieurs images différentes. Nous avons donc considéré une séquence valide si sur la même caméra, les images sont prise à la suite dans un interval de temps inférieur à 2 secondes. Ce numéro est ainsi ajouté aux métadonnées et permet de réaliser des analyses plus approfondies.

4.2 Stockage des Données

Afin de stocker les données, nous utilisons deux espaces de stockage différents. Premièrement, nous utilisons le serveur atlas mis à disposition pour stocker les images brutes. Deuxièmement, nous utilisons Google Drive pour stocker les subsets d’images traitées. De cette manière, nous avons une source de donnée fiable et pouvons ainsi tous travailler en parallèle avec les mêmes données uniformisées.

Datalake Les données désarborisées ainsi que les données originales sont stockées sur le serveur atlas dans le dossier `/home/crapauduc/data/`. Ce dossier est accessible à tous les membres du groupe. Les images sont stockées dans des dossiers par caméra et le nom de fichier est la date ISO standardisée de la date de la prise du fichier.

Subsets Les subsets sont stockés dans le Google Drive et peuvent être utilisé pour tester//entraîner différents algorithmes

Chapter 5

Filtrage

Idée générale Le but de ce chapitre est de décrire les différentes méthodes de filtrage investiguées, dans le but d'améliorer la qualité des données.

Problème Le dataset original est composé de 18 caméras regroupant environ 1 million d'images. Une bonne partie de ces images sont des faux positifs. Il est donc nécessaire de filtrer les images afin de ne garder que les images qui nous intéressent. Une première observation nous fait remarquer que les images uniquement constituées de feuilles n'ont jamais d'animaux. Ensuite, une deuxième lecture nous fait remarquer que les animaux se déplacent plus facilement par temps humide. Et finalement, nous constatons que les animaux sont nombreux certains jours. À partir de ces observations, nous avons élaboré 3 méthodes pour filtrer les images et ainsi augmenter notre probabilité de trouver des animaux pour constituer de nouveaux labels ou constituer un dataset de validation. Ces méthodes sont décrites dans les sections suivantes.

5.1 Analyse des données labellisées

Comme dit en introduction, notre professeur monsieur Satizabal Mejia Hector Fabio nous a fourni les bounding box pour certaines images. C'est sur le fichier "path_and_bounding_box.csv" - que nous avons préalablement créé à partir de ces données - que nous avons effectué l'analyse exploratoire des données. Nous nous basons ainsi 2020 images dont :

- 224 observations de tritons ;
- 201 observations de grenouilles-crapauds.

Ces données s'étendent sur la période du 9 mars au 15 avril 2017. Il est premièrement important de noter que les données contenant des tritons et/ou des grenouilles-crapauds s'étendent du 9 mars au 1er avril, c'est-à-dire que l'on en a pas observé entre le 1er avril et le 15 avril. Nous avons donc observé la présence de tritons et/ou grenouille-crapaud au travers de ces données via des variables temporelles - heure et jour - et via des variables météorologiques - telles que humidité, température ou précipitation.

Aussi, il est important de noter ici que plusieurs images peuvent faire partie du passage du même objet ; l'ensemble de données compte en effet 425 images dont environ prises. C'est pourquoi nous resterons très généraux pour cette première analyse des données. Voici donc ce que l'on a observé sur les données contenant des tritons et/ou des grenouilles-crapauds :

5.1.1 Analyse temporelle

Date




Figure 5.1: Fréquentation des objets en fonction de la date




Figure 5.2: Fréquentation des batraciens observés en fonction de la date

On observe donc d'après la figure 5.2 que les batraciens d'intérêt utilisent particulièrement les crapauds en mois de mars. Le reste des observations durant cette période, nous indique cependant que l'on observe peu de données en avril.

Cependant, d'après quelques recherches (cliquer sur le mot pour suivre la source) sur internet, les batraciens se reproduisent en fin février-début mars. On peut donc considérer que la déduction de fréquentation plus élevée des crapauds par les batraciens en mars peut être considérée pour un premier filtrage pertinent des images.

Heure

D'après la figure 5.4, on observe que les batraciens d'intérêt utilisent particulièrement - même uniquement, pour cet ensemble de données - les crapauds entre 19h et 7h du




Figure 5.3: Fréquentation des objets en fonction de la date

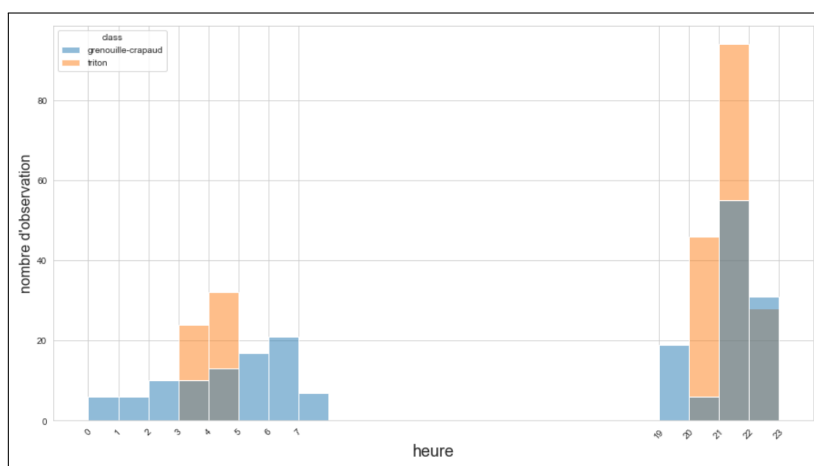


Figure 5.4: Fréquentation des batraciens observés en fonction de l'heure

matin, c'est-à-dire de nuit. Le reste des observations confirme premièrement la pertinence de cette observation, étant donné que nous avons une quantité élevée d'images prises tout au long de la journée parmi l'ensemble de données étudié ici.

Les quelques recherches faites sur la période de déplacement des batraciens à l'étang indiquant également qu'elle est particulièrement durant le crépuscule, on confirme ainsi la pertinence que peut avoir ce deuxième filtrage des images.

5.1.2 Analyse météorologique

5.2 Détecteur de planches

Nous avons développé un réseau de neurones convolutif à l'aide de la librairie PyTorch. Ce classificateur binaire, prédit ou non la présence de planche.

Dataset d'entraînement Nous avons extrait 600 images d'une même caméra et labellisé 359 non planches et 241 planches. Ensuite, nous avons développé un dataloader permettant d'intégrer nos labels et de charger des batchs de données directement dans la librairie Py-

Torch. Celui ci, utilise un pipeline d'entrée qui applique plusieurs transformations à l'image avant de pouvoir l'utiliser comme un tenseur.




Figure 5.5: Exemple de données d'entraînement

Architecture du Détecteur Le détecteur est simplement constitué de 3 couches convolutives suivi de 2 couches entièrement connectées. Les channels d'entrée et de sortie des couches convolutives est de : 3 - 32, 32 - 64, 64 - 128. Le nombre de neurones des couches fully connected sont de 128 et 1 pour le neurone de sortie. La fonction de coût utilisé est la BCELoss et l'optimiseur est Adam. Le réseau est entraîné pendant 10 epochs avec un learning rate de 0.001 et un momentum de 0.9 sur 3 epochs.




Figure 5.6: Matrice de confusion du détecteur de planche

Résultats Le détecteur de planche a une précision de 1 et un recall de 0.98 sur la détection de planche. En revanche, la précision sur la détection de non planche est de 0.88 et un recall de 1. Ce qui veut dire que notre filtre est un peu trop efficace et a tendance à se tromper pour détecter les images sans planche. Comme les résultats sont satisfaisant pour dégrossir le travail, nous n'avons pas passé de temps supplémentaire à optimiser le réseau afin qu'il sépare mieux les images dotés d'une planche ou non. Comme, nous traitons une grande quantité de données, l'erreur est acceptable. Lancé sur la quasi intégralité du dataset, le filtre a tourné pendant plus de 10h sur un ordinateur de bureau doté d'un processeur Ryzen9500X. Au final, le filtre a détecté 48910 images de non planches sur les 754543 images analysées.

Chapter 6

Modèles

6.1 Choix des modèles

Le choix des modèles a été un choix rapide.

Nous avons commencé par regarder les tutoriels sur les sites web des frameworks que nous utilisons. Nous avons donc regardé les tutotiels de pytorch, car nous voulions utiliser ce framework en particulier, mais avons aussi regardé les githubs de modèles dont nous avons entendu parler, comme YOLOv5. Il faut noter que notre compréhension du problème et du jargon utilisé dans le domaine s'est enrichi au fur et à mesure de nos recherches.

Ainsi, nos premiers choix peuvent sembler mauvais, mais lors de la prise de décision nous étions persuadés de faire les bons choix. Notre approche de départ se basait essentiellement sur un facteur: nous voulions des modèles pour lesquels il existe beaucoup de ressources en ligne. Cette méthodologie nous a amené à explorer une solution (YOLOv5) qui n'était pas adaptée à notre problème.

Après beaucoup d'essais infructueux, nous avons donc changé de méthodologie et nous nous sommes laissé la liberté d'utiliser des outils de plus haut niveau, tel que Detectron2 et de ne pas se restreindre uniquement à PyTorch. Une fois que nous avons pris en main ce framework, nous avons pu nous concentrer sur la performance du modèle. C'est aussi à ce stade que nous avons compris que le score sur le benchmark COCO2017 indiqué sur beaucoup de documentation de modèles était justement indiqué pour pouvoir comparer les modèles entre eux.

6.2 Les échecs

YOLOv5

YOLO est l'acronyme de You Only Look Once; il s'agit du premier modèle que nous avons essayé. Nous avons décidé de commencer avec ce modèle pour plusieurs raisons parmi lesquelles : une abondance de tutoriels sur le net et une solution qui nous semblait clé en main pour résoudre notre problème. Malgré ces signes positifs, il n'a pas été une solution adaptée.

En effet, YOLO, a été publié il y a plusieurs année et n'est plus forcément l'état de l'art actuel. De plus, ce modèle est adapté à du traitement en temps réel ce qui ne fait pas partie de notre problème. Cependant, le réel souci qui nous a fait abandonner cette solution est la structure spéciale du dataset qui ne correspondait pas à notre structure.

Durant une phase de réflexion visant à résoudre le souci de structure, nous avons ainsi réalisé

l'incapacité du modèle à gérer des images n'étant pas de 640x640 pixels. Nous aurions pu effectuer un réajustement de la taille des images mais ces derniers éléments nous ont fait réaliser que YOLO n'était pas la solution clé à laquelle nous nous attendions et avons décidé après quelques discussions de passer à un modèle plus adapté à notre problème initial. C'est ainsi que nous nous sommes lancé sur faster R-CNN, un modèle qui supporte des images de tailles arbitraires et qui est plus récent que YOLOv5.

SSD

Faster RCNN avec Keras

6.3 FASTER R-CNN

source1 : <https://towardsdatascience.com/r-cnn-fast-r-cnn-faster-r-cnn-yolo-object-detection-algorithms-36d53571365e>

source2 : <https://stackoverflow.com/questions/48318448/understanding-basic-difference-between-a-cnn-and-rnn>

+ check videos en cherchant "rcnn, fast rcnn, faster rcnn" sur google

Description

- Histoire (evolution de RCNN)
- Date du papier l'expliquant
- architecture
- Score benchmark coco

Adapter les exemples sur un problèmes légèrement différent : bullshiter sur assembler différent tutoriaux nécessite de comprendre, perte de temps sur manque de connaissance du jargon technique : mAP, etc les benchmarks coco, comprendre que coco (Common Object in COntext) est beaucoup de chose (dataset, benchmark baseline, dataset d'entraînement)

6.4 RETINA net

Description

Results

6.5 DEtection Transformer (DE-TR)

DETR est un modèle sorti en 2020 qui est extrêmement simple à implémenter et fournit des scores (mAP, IoU etc) sur le dataset COCO qui surpassent ceux des modèles existants de quelques points. C'est pourquoi, en plus de son architecture innovante, nous avons voulu l'essayer. L'architecture, visible en figure 6.1, se base sur un transformer, un modèle de deep learning parut dans le fameux papier de 2017 de Google, *Attention is all you need*. On peut observer que le modèle commence par générer des features à partir de l'image d'entrée

en utilisant une backbone c'est à dire un modèle pré-entraîné visant justement à extraire ces features à l'aide d'un réseau convolutionnel. Ensuite, le modèle utilise la partie encodeur du transformer suivit du décodeur et finalement d'un **prediction feed-forward networks** (FFN). C'est le réseau FFN qui génère les possibles bounding boxes et les classes associées.




Figure 6.1: Architecture de DETR

Chapter 7

Evaluation

7.1 Section1

paragraph1

7.1.1 Features

Dans une tâche d'object detection, nous utilisons le score IoU qui signifie Intersection over Union. C'est un score qui compare les bounding boxes prédites par le modèle avec les bounding boxes réels (ground-truth). Une tâche d'object detection comprend deux sous-problèmes: la classification et la localisation. Ainsi nous avons plusieurs métriques pour analyser la performance d'un modèle. IoU se concentre sur la localisation des bounding box prédites tandis que la métrique mAP (mean Average Precision) se concentre sur la classification. Ceci est un acronyme k-nearest neighbor




Figure 7.1: Intersection over Union

Chapter 8

Comptage

8.1 Section1

paragraph1

8.1.1 Features

Chapter 9

Conclusion

Ceci est un acronyme k-nearest neighbor